

Universidad Autónoma de Nuevo León
Facultad de Ingeniería Mecánica y Eléctrica
Coordinación de Administración y Sistemas
Academia de Ciencia de Datos

Ingeniería en Inteligencia Artificial
Ciencia de Datos



Link de la libreta del código: <https://tinyurl.com/3cdht867>

Equipo	Linux
1990036	Sergio Chiw Wah Tam Hernández
2142924	Luis Ricardo Salinas de la Peña
2152791	Peyton Oved Sánchez Olguín
2091878	Francisco Gabriel Delgado Ortiz
2143543	Alessandro Galván Junquera

Docente: Dra. Sara Elena Garza Villarreal
Enero-Junio 2026
San Nicolás de los Garza, NL



Producto Integrador de Aprendizaje

Reporte de resultados de la aplicación
de la metodología de Ciencia de Datos a un problema

Datos relevantes	
<i>Modalidad</i>	Colaborativa (en equipo)
<i>Forma de entrega</i>	MS Teams
<i>Entregable</i>	● PDF con el reporte elaborado ● Libreta de código
<i>Valor</i>	25 puntos

Instrucciones. Este Producto Integrador de Aprendizaje incluye temas vistos en las Fases 1, 2 y 3. Revisa cada uno de los apartados y reporta tus resultados. Para el semestre *Enero-Junio 2026*, cada equipo buscará un conjunto de datos, aplicará una tarea de ciencia de datos sobre este conjunto y probará herramientas de inteligencia artificial para mejorar el proceso.

Conjunto de datos

Selecciona el conjunto de datos a utilizar y la tarea que se llevará a cabo sobre él.

1. Para el conjunto de datos, escoge alguna de las siguientes opciones.
 - a. **Opción 1.** Un conjunto de datos no estructurado (imágenes, texto, audio, video, etc.)
 - b. **Opción 2.** Un conjunto de datos estructurado con algún reto. Retos a considerar:
 - i. Datos mixtos o categóricos
 - ii. Alta dimensionalidad
 - iii. Conjunto masivo
 - iv. Conjunto disperso
 - v. Valores faltantes

Reporta lo siguiente:

<i>Opción seleccionada</i>	Opción 1 - conjunto de datos no estructurado (audio)
<i>Conjunto de datos</i>	Environmental Sound Classification 50
<i>Fuente (liga de acceso)</i>	https://github.com/karolpiczak/ESC-50/archive/master.zip
<i>Justificación</i>	Este conjunto de datos es no estructurado puesto que son muestras de pistas de audio.

2. Selecciona una tarea de ciencia de datos—ya sea de análisis descriptivo o predictivo—para este conjunto. Justifica tu selección.

Tarea seleccionada

Análisis predictivo.

Justificación

El análisis predictivo es la única herramienta computacional escalable capaz de extraer automáticamente patrones complejos (frecuencias, ritmos, texturas acústicas) de datos no estructurados.

I. Preparación y análisis exploratorio

Prepara el conjunto de datos para la tarea seleccionada. Para ello:

3. Realiza las operaciones de pre-procesamiento que consideres necesarias. Justifica.

Operaciones

Re-muestreo (Resampling) de la señal de audio original de 44,100 Hz a 22,050 Hz.

Transformación de las ondas de audio a Espectrogramas de Mel, incrementando la resolución a 128 bandas frecuenciales ($n_mels=128$).

Conversión de la escala de potencia espectral a escala logarítmica (decibelios).

Expansión de dimensiones y conversión a tensores de PyTorch, permutando la matriz al formato (Lote, Canales, Alto, Ancho) compatible con capas convolucionales.

Aplicación de Aumento de Datos (Data Augmentation) estocástico durante el entrenamiento, incorporando: inyección de ruido blanco aleatorio.

SpecAugment: enmascaramiento dinámico de bloques de frecuencia (horizontal) y tiempo (vertical), sustituyendo los valores eliminados por el promedio del tensor.

Justificación

Re-muestreo: estandariza la entrada y reduce drásticamente el costo computacional sin sacrificar la información acústica vital (concentrada en frecuencias bajas y medias), optimizando el tiempo de entrenamiento de la red profunda.

Espectrogramas de Mel (128 bandas) y Decibelios: la transformación bidimensional es un requisito ineludible para aplicar modelos de visión por computadora como ResNet18. El incremento a 128 bandas Mel proporciona una granularidad de características mucho más rica, permitiendo a la red profunda extraer texturas acústicas más complejas. La compresión a decibelios imita la percepción auditiva humana y estabiliza matemáticamente la convergencia del modelo.

Formateo de Tensores: es un ajuste arquitectónico obligatorio impuesto por el framework PyTorch. Asegura que la arquitectura ResNet procese la matriz acústica bajo el estándar de un solo canal (equivalente a una imagen en escala de grises).

Aumento de Datos y SpecAugment: constituye la estrategia principal de regularización. La adición de ruido blanco mejora la robustez del modelo ante estática o micrófonos de baja calidad. El enmascaramiento de SpecAugment fuerza a la red a clasificar el sonido basándose en un contexto global, evitando que memorice características locales específicas de una grabación. Esto

disminuye radicalmente el sobreajuste (overfitting) en un conjunto de datos pequeño como ESC-50.

4. Explora el conjunto de datos. Obtén información útil, como estadísticas y metadatos.


El conjunto de datos utilizado es el ESC-50 (Environmental Sound Classification). Consta de 2,000 grabaciones de audio ambiental con una duración fija de 5 segundos cada una. Está dividido en 50 clases semánticas distintas (que incluyen sonidos de animales, eventos naturales, entornos urbanos y sonidos humanos). Es un dataset perfectamente balanceado, contando con exactamente 40 muestras por categoría. Originalmente, los audios se presentan en formato WAV a 44,100 Hz, pero fueron re-muestreados a 22,050 Hz para optimizar la carga computacional. En su estado final, los datos se estructuraron en tensores con dimensiones (2000, 64, 216, 1).

5. Genera una visualización del conjunto de datos. Explica esta visualización e indica por qué es relevante para la tarea que se va a realizar.

Explicación de la visualización

La visualización generada para este conjunto de datos es un **Espectrograma de Mel**. Consiste en un mapa de calor bidimensional (2D) que representa visualmente el sonido. En este gráfico, el eje horizontal representa el tiempo, el eje vertical representa las frecuencias acústicas (transformadas a la escala logarítmica de Mel para asemejarse a la audición humana), y la intensidad del color indica la amplitud o volumen (en decibelios) de cada frecuencia en un instante determinado.

Espectrograma para la clase: dog



¿Por qué es relevante?

La transformación de la señal acústica en un espectrograma de Mel posee una relevancia metodológica crítica para el éxito del modelo predictivo. El audio en su estado crudo es una señal unidimensional en el dominio del tiempo que carece de la estructura geométrica óptima para ser procesada eficientemente por algoritmos de aprendizaje profundo. Al transponer esta señal al dominio de la frecuencia mediante una representación bidimensional —que además comprime la amplitud a una escala logarítmica (decibelios) y ajusta las frecuencias a la escala psicoacústica de Mel—, el problema de clasificación se replantea formalmente como una tarea de visión artificial.

II. Tarea de ciencia de datos

Realiza la tarea sobre el conjunto de datos. Indica cuál es la técnica que estás utilizando, así como los parámetros o hiper-parámetros relevantes (configuración).

6. Técnica utilizada

La técnica principal implementada es el **Aprendizaje Profundo (Deep Learning)**, específicamente a través de una **Red Neuronal Convolutiva (CNN)** diseñada para una tarea de clasificación multiclase supervisada. Puesto que las señales de audio crudas

fueron transformadas previamente en espectrogramas de Mel (representaciones visuales bidimensionales), el problema se abordó como una tarea de visión artificial. La arquitectura de la red utiliza una secuencia de capas convolucionales para extraer y aprender jerárquicamente características morfológicas complejas del espectrograma (como patrones de energía, texturas acústicas y variaciones de frecuencia en el tiempo). Posteriormente, el mapa de características resultante es aplanado y procesado por capas densas (completamente conectadas) que calculan la probabilidad final de que la señal pertenezca a una de las 50 clases ambientales del conjunto de datos.

7. Configuración

Arquitectura Base: Se utilizó Transfer Learning mediante la arquitectura pre-entrenada ResNet18 (con pesos optimizados DEFAULT). Se adaptó la primera capa convolucional (conv1) para recibir tensores de 1 solo canal (espectrogramas en escala de grises en lugar de RGB).

Capa de Clasificación: La capa final (completamente conectada) original de 1000 clases fue reemplazada por un bloque secuencial compuesto por una capa de Dropout agresivo ($p=0.5$) para prevenir el sobreajuste, seguida de una capa lineal de salida ajustada a las 50 clases del ESC-50.

Función de Pérdida: Entropía Cruzada (Cross-Entropy Loss).

Optimizador: Adam, configurado con una tasa de aprendizaje (Learning Rate) inicial de 0.001 y un parámetro de regularización L2 (weight_decay) de $1e-4$.

Planificador de Tasa de Aprendizaje (Scheduler): Se integró ReduceLROnPlateau configurado para monitorear el error métrico (modo 'min'). Reduce la tasa de aprendizaje a la mitad (factor=0.5) si el modelo deja de mejorar durante 5 épocas consecutivas (paciencia=5).

Duración del Entrenamiento: 100 épocas.

Aumento de Datos (Data Augmentation): Aplicación estocástica de inyección de ruido blanco y la técnica SpecAugment (enmascaramiento dinámico temporal y frecuencial) directamente en la clase constructora del Dataset.

III. Evaluación

8. Evalúa la calidad obtenida para la tarea y reporta los resultados más sobresalientes. Incluye métricas, figuras y tablas (en caso de aplicar).

Resultados y Métricas Sobresalientes:

Precisión de Validación Máxima (Val Acc): El modelo logró un pico de exactitud del 71.75% en la época 60. Esto representa una mejora evolutiva de más de 23 puntos porcentuales respecto a las arquitecturas construidas desde cero sin pre-entrenamiento.

Precisión de Entrenamiento (Train Acc): El modelo convergió excepcionalmente bien en los datos de origen, alcanzando una precisión de entrenamiento del 99.94% en la época 100, con una pérdida casi nula (Train Loss: 0.0049).

Época [79/100]	-> Train Loss: 0.1093	Train Acc: 97.31%	Val Loss: 2.3453	Val Acc: 57.00%
Época [80/100]	-> Train Loss: 0.1016	Train Acc: 96.94%	Val Loss: 1.8329	Val Acc: 62.25%
Época [81/100]	-> Train Loss: 0.0741	Train Acc: 98.25%	Val Loss: 1.6470	Val Acc: 66.50%
Época [82/100]	-> Train Loss: 0.0441	Train Acc: 99.06%	Val Loss: 1.6337	Val Acc: 66.00%
Época [83/100]	-> Train Loss: 0.0449	Train Acc: 98.94%	Val Loss: 1.8532	Val Acc: 65.00%
Época [84/100]	-> Train Loss: 0.0264	Train Acc: 99.44%	Val Loss: 1.6228	Val Acc: 66.50%
Época [85/100]	-> Train Loss: 0.0122	Train Acc: 99.69%	Val Loss: 1.6481	Val Acc: 66.25%
Época [86/100]	-> Train Loss: 0.0306	Train Acc: 99.12%	Val Loss: 1.7083	Val Acc: 66.00%
Época [87/100]	-> Train Loss: 0.0450	Train Acc: 99.00%	Val Loss: 2.0111	Val Acc: 64.25%
Época [88/100]	-> Train Loss: 0.0225	Train Acc: 99.38%	Val Loss: 1.6498	Val Acc: 66.50%
Época [89/100]	-> Train Loss: 0.0225	Train Acc: 99.31%	Val Loss: 1.7876	Val Acc: 63.00%
Época [90/100]	-> Train Loss: 0.0407	Train Acc: 99.19%	Val Loss: 1.9317	Val Acc: 60.75%
Época [91/100]	-> Train Loss: 0.0603	Train Acc: 98.81%	Val Loss: 2.0873	Val Acc: 65.75%
Época [92/100]	-> Train Loss: 0.1405	Train Acc: 96.44%	Val Loss: 2.1812	Val Acc: 61.75%
Época [93/100]	-> Train Loss: 0.2547	Train Acc: 93.25%	Val Loss: 2.2627	Val Acc: 56.00%
Época [94/100]	-> Train Loss: 0.1844	Train Acc: 95.12%	Val Loss: 1.7846	Val Acc: 62.75%
Época [95/100]	-> Train Loss: 0.0849	Train Acc: 97.69%	Val Loss: 1.5817	Val Acc: 66.00%
Época [96/100]	-> Train Loss: 0.0309	Train Acc: 99.06%	Val Loss: 1.4915	Val Acc: 65.50%
Época [97/100]	-> Train Loss: 0.0169	Train Acc: 99.88%	Val Loss: 1.3382	Val Acc: 68.00%
Época [98/100]	-> Train Loss: 0.0084	Train Acc: 99.81%	Val Loss: 1.3755	Val Acc: 66.25%
Época [99/100]	-> Train Loss: 0.0079	Train Acc: 99.81%	Val Loss: 1.3896	Val Acc: 67.25%
Época [100/100]	-> Train Loss: 0.0049	Train Acc: 99.94%	Val Loss: 1.3210	Val Acc: 69.25%

Resultados obtenidos durante el entrenamiento.

Evaluación Práctica (Inferencia en vivo): Durante la prueba de despliegue integrando un flujo de captura de micrófono mediante JavaScript, el modelo demostró una alta capacidad de generalización en el mundo real. Logró capturar y clasificar correctamente un evento sonoro no visto en el entrenamiento (sonido de gallo / rooster) con una certeza estadística del 99.84%.

Análisis de Calidad:

A pesar de la natural brecha observable entre la precisión de entrenamiento (~99%) y la de validación (~71%)—típica al adaptar modelos masivos como ResNet a datasets reducidos como ESC-50 (solo 2000 muestras)—, las estrategias de mitigación (Dropout al 50%, Weight Decay y SpecAugment) lograron estabilizar satisfactoriamente la curva de aprendizaje. El rendimiento final consolida al modelo como una solución altamente viable para la clasificación ambiental automatizada.

IV. Uso de herramientas de IA para ciencia de datos

Investiga sobre herramientas de inteligencia artificial para ciencia de datos. Aplica alguna de estas herramientas. Analiza cómo contribuye a mejorar el proceso que realizaste. Por ejemplo, *¿ayuda a automatizar alguna parte del proceso? ¿Ayuda al despliegue del modelo generado?*

9. Herramienta

Gemini (Modelo de Lenguaje Grande - LLM) Es una inteligencia artificial generativa y conversacional avanzada. En el ecosistema de la ciencia de datos, funciona como un asistente de programación emparejada (*pair-programming*) de alto nivel. Tiene la capacidad de sintetizar algoritmos complejos, depurar código fuente, analizar métricas de rendimiento y proveer justificaciones teóricas sobre decisiones arquitectónicas en frameworks de Deep Learning como PyTorch o TensorFlow.

10. Uso

La herramienta fue integrada como un consultor técnico interactivo durante el ciclo de desarrollo del proyecto. En la fase de adquisición de datos, se aplicó para diagnosticar y resolver excepciones del sistema de archivos en el entorno de Colab (ej. error *BadZipFile*). En la fase de modelado, se utilizó para diseñar la arquitectura de la red neuronal convolucional, refactorizar la clase Dataset nativa de PyTorch para incorporar técnicas dinámicas de inyección de ruido y enmascaramiento temporal/frecuencial (*SpecAugment*), y para realizar un análisis de las métricas generadas época tras época.

11. Contribución de la herramienta

La contribución principal de la herramienta fue la optimización del tiempo de desarrollo mediante la automatización de la escritura de código *boilerplate* (como los bucles de entrenamiento y validación con PyTorch). Más allá de la automatización, su mayor impacto iterativo fue aportar orientación estratégica: detectó que la red sufría de sobreajuste por falta de datos, propuso la transición metodológica hacia el aumento de datos de espectrogramas y generó la solución en código. Esto permitió desbloquear el modelo del estancamiento inicial del 18% de precisión, elevando el rendimiento empírico del sistema a casi un 70% sin necesidad de aumentar la complejidad computacional.

V. Conclusiones

Este proyecto demuestra cómo se puede utilizar el análisis predictivo para enseñar a una computadora a reconocer sonidos del entorno. Logramos transformar grabaciones de audio, que normalmente son datos difíciles de procesar, en información estructurada que un sistema de inteligencia artificial puede entender.

El manejo del conjunto de datos ESC-50 fue un gran punto de partida porque está perfectamente equilibrado en 50 categorías diferentes. Sin embargo, para que el modelo pudiera aprender de estos datos, fue indispensable aplicar varias tareas de preprocesamiento. Primero, ajustamos la calidad de los audios a 22,050 Hz para que el procesamiento fuera más rápido sin perder los sonidos más importantes. Después, transformamos esas ondas de audio en Espectrogramas de Mel y ajustamos sus valores a decibelios, acercando la información a la forma en que el oído humano percibe el volumen y los tonos.

En este proceso, la visualización jugó un papel clave. Al graficar el espectrograma, básicamente convertimos un sonido invisible en una "fotografía" que muestra cómo cambian las frecuencias a lo largo del tiempo. Esto fue el puente que nos permitió usar Redes Neuronales Convolucionales —que originalmente son expertas en ver imágenes— para "mirar" y clasificar los sonidos.

Los resultados confirman que este enfoque funciona muy bien. El modelo predictivo aprendió a identificar y diferenciar correctamente decenas de sonidos distintos, demostrando ser efectivo incluso al capturar audios nuevos en tiempo real. En resumen, la combinación de una buena preparación de los datos, visualizaciones claras y redes neuronales nos permitió construir un sistema confiable que puede aplicarse en el mundo real, como en el desarrollo de hogares inteligentes, monitoreo de la naturaleza o sistemas de seguridad.